

金陵科技学院

毕业设计(论文)开题报告



设计(论文)题目: 面向无人驾驶的深度强化学习算法

应用与研究

学生姓名: 王家骅 学号: 1613902007

专 业: 计算机科学与技术

所在学院: 计算机工程学院

指导教师: 龚如宾

职 称: 讲师

2019 年 12 月 22 日

开题报告填写要求

1. 开题报告（含“文献综述”）作为毕业设计（论文）答辩委员会对学生答辩资格审查的依据材料之一。此报告应在指导教师指导下，由学生在毕业设计（论文）工作前期内完成，经指导教师签署意见及所在专业审查后生效；

2. 开题报告内容必须用黑墨水笔工整书写或按教务处统一设计的电子文档标准格式打印，禁止打印在其它纸上后剪贴，完成后应及时交给指导教师签署意见；

3. “文献综述”应按论文的格式成文，并直接书写（或打印）在本开题报告第一栏目内，学生写文献综述的**参考文献应不少于 15 篇**（不包括辞典、手册）；

4. 有关年月日等日期的填写，应当按照国标 GB/T 7408—94《数据元和交换格式、信息交换、日期和时间表示法》规定的要求，一律用阿拉伯数字书写。如“2017 年 4 月 26 日”或“2017-04-26”。

5、开题报告（文献综述）字体请按宋体、小四或五号字体书写，行间距 1.5 倍（英文字体可采用其它合适的字体，但正文中的英文字体应统一，否则显得凌乱）。

6、对每一部分要审清标题，不符合标题的内容不能写入，一定不要把各种材料拿来拼凑某部分的篇幅。

7、**绝对不能把网上（或书中）材料简单地拷入自己的开题报告（否则一票否决），一定要进行消化整理，用自己的语言，写出相关的内容。**

8、指称同一概念的名词，全文中使用要统一（如 AJAX 与 Ajax、WEB 与 Web，只能用其中的一种），以免造成读者的疑问和报告的不规范。

9、注意一定用书面语、务必避免口语化倾向，要用客观描述的科技文体，不使用绝对化词语以及夸张的文学词汇及表达，不能有对某种产品的夸张性宣传。

毕 业 设 计（论文） 开 题 报 告

1. 结合毕业设计（论文）课题情况，根据所查阅的文献资料，每人撰写不少于 1500 字左右的文献综述：

一、选题背景和目的

无人驾驶是现在产业界和学术界的热点课题，它能够对交通事故的减少产生积极作用，并且能够减少交通拥堵，实现更有效地城市规划。同时它也能够对我国经济情况产生积极影响，研究显示，我国每年的拥堵成本占 GDP 的 2%左右。据公安部数据，截至 2017 年底，我国机动车保有量约 3.10 亿辆。其中汽车约 2.17 亿辆，占比 70%；汽车驾驶人达 3.42 亿人。从分布上看，全国有 53 个城市的汽车保有量超过 100 万辆，24 个城市汽车保有量超过 200 万辆，7 个城市超过 300 万辆，2018 年由于拥堵带来的经济损失占城市人口可支配收入的 20%。巨大的交通流量加上昂贵的拥堵成本，智慧交通俨然成为了我国现阶段交通治理合理的解决方法。

近年来，随着人工智能的不断发展，深度强化学习（Deep Reinforcement Learning, DRL）算法已经成为此领域当中最受关注的算法之一。DRL 将深度学习与强化学习结合起来，可被用于解决复杂系统的感知决策问题，在目前的许多无人驾驶研究中也广泛使用。

但是，目前的无人驾驶技术并不是非常成熟，许多方面还有待优化，例如提高自动化驾驶程度，提高物体识别精度，传感器失效时的出错处理等。而这些问题正是无人驾驶可靠性的衡量标准，解决这些问题对于无人驾驶领域而言有着重大的意义。由此，面向无人驾驶的深度强化学习算法的研究就有很大的必要性。本次毕业设计将先在模拟环境中训练模型，经过试验提高驾驶环境图片中车道及障碍物的识别精度，并得出合适的奖励函数使模型趋于完善，训练出在虚拟环境中能够安全和舒适驾驶的无人驾驶模型，然后把模型投入实际环境中的树莓派小车上运行，使其能够正常进行无人驾驶。

本课题主要是针对无人驾驶对深度强化学习算法进行研究，通过反复实验将模型训练到一个较优状态，使得无人小车在实际环境中正常进行自动驾驶。

二、文献综述

世界范围内有许多公司都在研究无人驾驶^[1-2]，美国谷歌公司作为最先发展无人驾驶技术的公司，其研制的全自动驾驶汽车能够实现自动启动行驶与停车。谷歌自动驾驶汽车项目重组为一家名为 Waymo 的独立公司。Waymo 于 2017 年 11 月 7 日对外宣

布，将对不配备安全驾驶员的无人驾驶汽车进行测试。除了传统汽车业强国与谷歌等互联网企业已经开始无人驾驶汽车的研发并且已经取得了相当好的成果之外，苹果、Uber 等也已经将业务范围向无人驾驶汽车倾斜。

而国内的无人驾驶领域也有了一定的成果，国内的百度、长安等企业以及国防科技大学、军事交通学院等军事院校的无人驾驶汽车走在国内研发的前列。例如长安汽车实现了无人驾驶汽车从重庆出发一路北上到达北京的国内无人驾驶汽车长途驾驶记录。百度汽车同样在北京进行了初次无人驾驶汽车在北京道路的实验并且取得了成功。

而到 2020 年，无人驾驶车辆有望在北京到崇礼的延崇高速路上实现道路测试。相关技术的快速发展无疑为无人驾驶的未来提供了强有力的技术支持。

深度强化学习^[3-4]通常指一些结合了深度学习和强化学习^[5]两种方法的一类机器学习方法，目前通过深度强化学习获得成功通常是以下的情况：控制器在环境状态中仅具有离散切有限的动作空间，并且没有复杂的内容，而讲深度强化学习应用于无人驾驶中则远非如此。例如在某些 Atari 游戏^[6]中仅有少数几个动作，或者是游戏 Go 这种虽然连续空间是高维的，但其规则和状态很容易从视觉上理解。在这些情况下，视觉问题很容易解决，因此 agent 只需要在行动空间有限的情况下优化策略。但对于无人驾驶，状态空间和来自环境的输入图像包含了极其复杂的背景和内部物体，它们会实时地进行动态变化并且行为难以预测。而一个可用的无人驾驶系统，恰恰需要在这样的复杂情况下做出正确的决策并快速地采取行动以保证行驶安全。

实现自动驾驶的一种直接方法是通过使用精确、可靠的硬件和传感器（例如激光雷达和惯性测量单元（IMU））来获取环境信息。这些硬件系统可以精确地重建 3D 信息，然后使用强化学习帮助车辆实现智能导航并且能够避免碰撞。但是这些硬件非常昂贵且部署繁重，而且它们只能给出 3D 物理表面的信息，而不是真正地了解环境，这并不是真正的智能，只能在固定的道路上行驶，无法应用到交通状况复杂多样的具体路面场景。

另一种解决方案是将视觉和强化学习算法结合起来，然后共同解决感知和决策问题。但是由于真实场景是十分复杂的，因此很难解决感知问题。真实环境中同样的对象在不同时刻或情况下可能会存在巨大的差异，例如颜色，物体的形状，物体的类型，背景和视角。静止的环境已经相当复杂，而无人驾驶中的环境会实时改变，分析的难度会更大。同时，由于动作空间是连续的并且可以同时执行不同的动作，控制问题在现实世界中也具有挑战性。例如为了使转向更平稳，可以同时转向和制动，并在转向

时调整转向度。而且，安全的自动驾驶汽车必须确保功能安全并能够应对紧急事件。例如，车辆必须非常小心十字路口和看不见的弯道，以便在有小孩突然横穿马路时立即行动或制动。而要解决这些问题，则需要选择合适的深度强化学习模型和足够的训练。

强化学习主要分为三类^[7]：

1. Value-based 方法，如：Q-Learning, Deep Q-Learning (DQN)^[8]。
2. Policy-based 方法，如 Policy Gradient, Proximal Policy Optimizer (PPO)^[9]等。
3. Actor-Critic 方法，如 Deep Deterministic Policy Gradient (DDPG)^[10], Asynchronous Advantage Actor-Critic (A3C)^[11], Soft Actor-Critic (SAC)^[12]。

为了选择合适的强化学习方法，有必要先了解与本课题相关的几种方法：

Deep Q-Learning (DQN)

DQN 是一种融合了神经网络和 Q learning 的 value-based 方法。传统的 Q learning 用表格来存储每一个状态 state, 和在这个 state 每个行为 action 所拥有的 Q 值。而对于比较复杂的问题, 状态会非常多(比如下围棋)，如果全用表格来存储它们，需要用到巨大的内存空间，而且每次在这么大的表格中搜索对应的状态也是一件很耗时的事。而 DQN 可以将状态和动作当成神经网络的输入，然后经过神经网络分析后得到动作的 Q 值，这样就没必要在表格中记录 Q 值，而是直接使用神经网络生成 Q 值。

Deep Deterministic Policy Gradient (DDPG)

DDPG 融合了 DPG 和 DQN 二者的思想。在此首先需要介绍 DPG (Deterministic Policy Gradient)，在 DPG 中，Policy gradient 部分被用来在连续动作上进行动作的筛选，而且筛选的时候是根据所学习到的动作分布随机进行筛选，而 Deterministic 则体现在改变了输出动作的过程，旨在连续动作上输出一个动作值。而 DDPG 用到的神经网络类似于 Actor-Critic，也需要有基于策略 Policy 的神经网络和基于价值 Value 的神经网络，但是为了体现 DQN 的思想，每种神经网络都需要再细分成两个。Policy Gradient 有估计网络和现实网络，估计网络用来输出实时的动作，而现实网络则是用来更新价值网络系统的。价值系统也有现实网络和估计网络，它们都在输出这个状态的价值，而输入则有不同，状态现实网络会用 actor 施加的动作当做输入。在实际运用中，DDPG 的这种做法的确带来了更有效的学习过程。

Actor Critic

Actor Critic 为类似于 Policy Gradient 和 Q-Learning 等以值为基础的算法的组合。Actor Critic 方法的优势在于可以进行单步更新,比传统的 Policy Gradient 要快。而其劣势在于它取决于 Critic 的价值判断,但是 Critic 难收敛,再加上 Actor 的更新,收敛就变得更为困难。

Asynchronous Advantage Actor-Critic (A3C) 是 Google DeepMind 提出的一种解决 Actor Critic 不收敛问题的算法。A3C 会创建多个并行的环境,让多个拥有副结构的 agent 同时在这些并行环境上更新主结构中的参数。并行中的 agent 们互不干扰,而主结构的参数更新受到副结构提交更新的不连续性干扰,所以更新的相关性被降低,收敛性提高。

Soft Actor-Critic (SAC) 是一个 off-policy actor-critic 深度强化学习算法,其要求 actor 同时最大化期望和策略分布的熵,旨在保证任务成果的同时希望策略尽可能的随机,这样的思想使它具有了更好的收敛能力和收敛过程中的稳定性。

Generative Adversarial Nets (GAN)

在模拟器上训练模型的同时,需要使用 GAN^[13-14]等技术来让从模拟器上得到的训练数据变得更接近现实,以便训练出能够应用于真实场景的模型。2014 年,Goodfellow 提出了生成对抗网络 (GAN)。该模型中含有两个神经网络,一个判别器 D (Discriminator) 用于判别图像真假,另一个生成器 G (Generator) 生成图片迷惑 D。实际上二者在相互切磋的过程中,各自的能力会不断加强。模型最终的目的是生成器 G 生成的图像能够以假乱真。

CGAN^[15-17]的概念也是在 2014 年被提出的。它是一种带条件约束的 GAN,在生成模型和判别模型的建模中均引入条件变量 y ,使用额外信息 y 对模型增加条件,可以指导数据生成过程。因此使用 CGAN 结构,通过合理的应用 y 变量,可以生成限定条件下的图片。CGAN 内部的生成器与判别器结构如图 1。

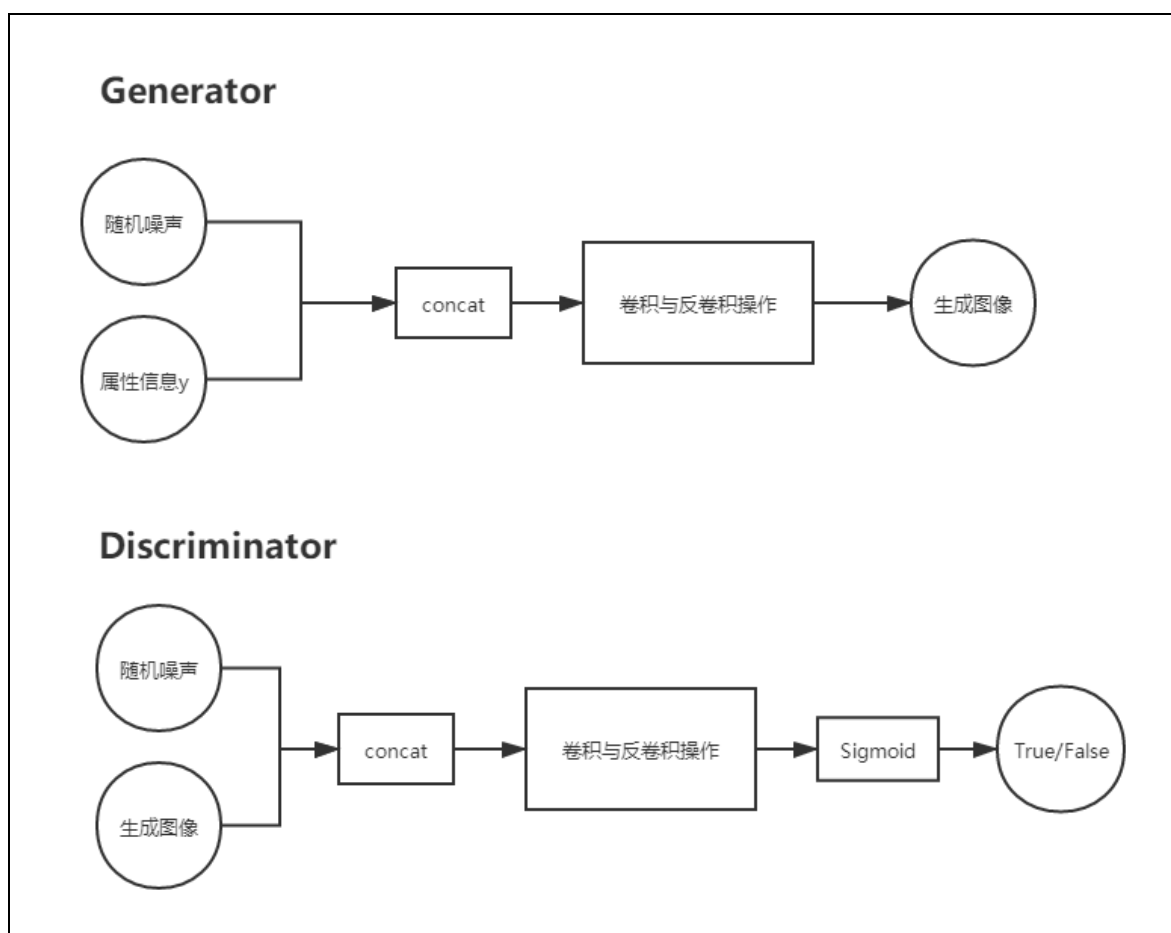


图 1 CGAN 内部结构

本项目将使用 python 语言，选取 PyTorch、Tensorflow、Keras 等框架中的一个来搭建多种用于无人驾驶的深度强化学习模型，并在 CARLA^[18]、DonkeyCar 模拟器上进行充分的训练，得到较好的表现后将可以投入使用的模型应用到 DonkeyCar 无人小车^[19]上，最终在真实世界中完成小车的无人驾驶，为真实的载人汽车驾驶提高重要的实验数据。本项目的研究具有重大的工程意义，能够提升人类生活品质，降低交通运营成本，还可以减少全球范围内的二氧化碳排放量以减缓全球变暖的影响。

三、参考文献

- [1] 张茜. 无人驾驶系统的设计与实现[J]. 电子技术与软件工程 . 2019
- [2] 张宇航. 无人驾驶汽车的起源、现状及展望[J]. 电子技术与软件工程 . 2017
- [3] V. Mnih et al., Playing Atari with Deep Reinforcement Learning, NIPS Workshop, 2013.
- [4] V. Mnih et al., Human-level control through deep reinforcement learning, Nature, 2015.
- [5] 郭宪, 方勇纯. 深入浅出强化学习: 原理入门 [M]. 电子工业出版社, 2018.

- [6] Mnih V , Kavukcuoglu K , Silver D , et al. Playing Atari with Deep Reinforcement Learning[J]. Computer Science, 2013, P 529.
- [7] 基于值函数和策略梯度的深度强化学习综述[J]. 刘建伟, 高峰, 罗雄麟. 计算机学报 . 2019
- [8] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double q-learning[C]//Thirtieth AAAI Conference on Artificial Intelligence. 2016.
- [9] John S, Filip W, Prafulla D, et al. Proximal Policy Optimization Algorithms[J]. arXiv preprint arXiv: 1707.06347, 2017
- [10] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[J].arXiv preprint arXiv:1509.02971, 2015.
- [11] Volodymyr M, Adrià Puigdomènech B, Mehdi M et al. Asynchronous Methods for Deep Reinforcement Learning. arXiv preprint arXiv: 1602.01783 ,2016
- [12] Tuomas H, Aurick Z et al. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. arXiv preprint arXiv: 1801.01290, 2018.
- [13] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, Yoshua Bengio. Generative Adversarial Networks[C] .arXiv preprint arXiv:1406.2661, 2014
- [14] 陈文兵, 管正雄, 陈允杰. 基于生成式对抗神经网络的数据增强方法[J/OL]. 计算用:1-8[2019-12-23].
- [15] 陆萍, 董虎胜. 基于条件生成对抗网络的图像生成 [J]. 甘肃科技纵横, 2019, 48(07):1-3.
- [16] 贾玉福, 胡胜红, 刘文平, 王超, 向书成. 使用条件生成对抗网络的自然图像增强方法[J]. 南京师大学报(自然科学版), 2019, 42(03):88-95.
- [17] Mehdi Mirza, Simon Osindero. Conditional Generative Adversarial Nets[C] . arXiv preprint arXiv:1411.1784, 2014
- [18] Dosovitskiy A, Ros G, Codevilla F, et al. CARLA: An open urban driving simulator[J]. arXiv preprint arXiv:1711.03938, 2017.
- [19] Q. Zhang and T. Du. Self-driving scale car trained by deep reinforcement learning[J]. arXiv preprint arXiv:1909.03467, 2019.

毕 业 设 计（论文） 开 题 报 告

2. 本课题要研究或解决的问题和拟采用的研究手段（途径）:

一、本课题研究目标

本课题的研究目标是设计并实现一个基于深度强化学习的无人驾驶算法。通过对比多种深度强化学习模型，选出几种可行性较大的方法并加以实现和调整，然后在模拟器上进行训练，对比结果，分析各种模型在不同情况下的优劣。最后训练出一个能够平滑地在赛道中驾驶，且具有一定避障能力的模型，然后将其投入到无人小车上实现真实环境中的驾驶。

主要研究目标如下：

1. 调用模拟器开放的 API，让模型能够与模拟器进行交互。
2. 选取和尝试不同的深度强化学习算法模型，收集实验数据，并基于实际需求进行修改和调整。
3. 比较几种模型在模拟器上的表现，分析其原因并加以改进。
4. 在算法中加入 CGAN 等技术来使模型能够在真实场景中应用。
5. 安装无人小车并将算法模型投入使用，观察实际表现并进行进一步改进和调优。

二、关键技术和难点

1. 各种深度学习框架的理解和应用。本项目很大程度上依赖于深度强化学习的各种算法，因此在理解深度强化学习理论上，熟悉和使用 Python 的各种深度学习框架就非常重要。
2. Actor-Critic 及其衍生算法的实现与优化。在 A2C、A3C 等算法的实际使用中需要考虑收敛困难的问题，需要通过共享训练网络等方法来提高训练效率。而由于本项目的输入数据取决于无人驾驶的传感器类型，需要让输入端能够同时接收视觉传感和其它传感器信息。
3. 奖励函数的设计。奖励函数的设定对模型最终的驾驶决策策略有着决定性的作用，需要经过多次实验来找出合适的奖励函数，实现安全舒适驾驶。
4. 在虚拟环境中能够安全舒适驾驶基础上，基于 CGAN 的画风转移技术，用于将虚拟环境中的模型应用于实际无人小车上，收集实验数据，为后续的实际路况中无人小车的学习和驾驶打好基础。

三、现有的研究基础

1. 深度强化学习是当前的研究热点，许多算法已经有了比较成熟的研究成果，斯坦福大学和伯克利有大量的英语教学课件视频，[github](#) 上也有许多案例可以参考，各大论坛、社区也有许多文章和视频资料可以学习。
2. 将深度强化学习应用于无人驾驶也已经有一些研究成果，有许多论文和已有的算法可以参考。
3. [Carla](#)、[DonkeyCar](#) 等无人驾驶模拟器具有丰富的 API，非常有利开发者在模拟器上进行模型训练和测试。
4. [tensorflow](#)、[PyTorch](#)、[Keras](#) 等框架的出现让机器学习的部署变得十分便利，为模型的搭建和调整省去了大量的时间。

四、实施方案

1. 部署 [python](#) 开发环境，使用 [Anaconda](#) 管理多个 [python](#) 解释器。并安装所需的 [python](#) 深度学习库和强化学习库，如 [tensorflow](#)、[Pytorch](#) 等。
2. 部署 [Carla](#)、[DonkeyCar](#) 等无人驾驶模拟器，并测试运行。熟悉它们的 API 以便在 [python](#) 中获取数据和驱动模拟器。
3. 采集数据并进行预处理。首先需要通过手动操作并控制模拟器中的车辆进行行驶，产生动作信息、环境图片以及通过其他 [Sensor](#) 得到的数据。训练集中的图片可能具有不同的分辨率，因此需要对它们进行预处理，首先调整图像分辨率并且保持一致的长宽比，然后对图片进行归一化。经过上述操作后输入数据的变化范围将被缩小，降低梯度失控发生的可能性。
4. 搭建算法模型。首先需要说明适用于大部分强化学习的逻辑流程，如图 1。




图 1 强化学习中 Agent 与环境的交互示意图

强化学习的基本原理是：

如果 Agent 的某个行为策略导致环境正的奖赏(强化信号)，那么 Agent 以后产生这个行为策略的趋势便会加强。Agent 的目标是在每个离散状态发现最优策略以使期望的折扣奖赏和最大。

强化学习把学习看作试探评价过程，Agent 选择一个动作用于环境，环境接受该动作后状态发生变化，同时产生一个强化信号(奖或惩)反馈给 Agent，Agent 根据强化信号和环境当前状态再选择下一个动作，选择的原则是使受到正强化(奖)的概率增大。选择的动作不仅影响立即强化值，而且影响环境下一时刻的状态及最终的强化值。

强化学习不同于监督学习，主要表现在教师信号上，强化学习中由环境提供的强化信号是 Agent 对所产生动作的好坏作一种评价(通常为标量信号)，而不是告诉 Agent 如何去产生正确的动作。由于外部环境提供了很少的信息，Agent 必须靠自身的经历进行学习。通过这种方式，Agent 通过行动从环境的评价中获得知识，改进行动方案以适应环境。

接下来介绍本次试验中预计进行实验的模型：

(1) Asynchronous Advantage Actor Critic (A3C):

要理解 A3C 首先需要明白其原型 Actor-Critic，Actor-Critic 的原理如图 2 所示。Actor Critic 为类似于 Policy Gradient 和 Q-Learning 等以值为基础的算法的组合。其中 Actor 类似于 Policy Gradient，以状态 s 为输入，神经

网络输出动作 actions，并从在这些连续动作中按照一定的概率选取合适的动作 action。Critic 类似于 Q-Learning 等以值为基础的算法，由于在 Actor 模块中选择了合适的动作 action，通过与环境交互可得到新的状态 s' ，奖励 r ，将状态 s' 作为神经网络的输入，得到 $v_{s'}$ ，而原来的状态 s 通过神经网络输出后得到 v 。通如下公式 1 得到 TD_{error} 。

$$TD_{error} = r + \gamma v_{s'} - v_s \quad (1)$$

最后通过状态 s ，动作 action，以及误差 TD_{error} 更新 Actor 网络的参数，实现单步更新。最后再将 s' 状态赋予给 s 状态。

因此，Actor-Critic 其实是结合了 Policy Gradient(Actor)和 Function Approximation (Critic)。Actor 基于概率选择行为，Critic 基于 Actor 的行为评判行为的得分，而 Actor 根据 Critic 的评分修改选择行为。

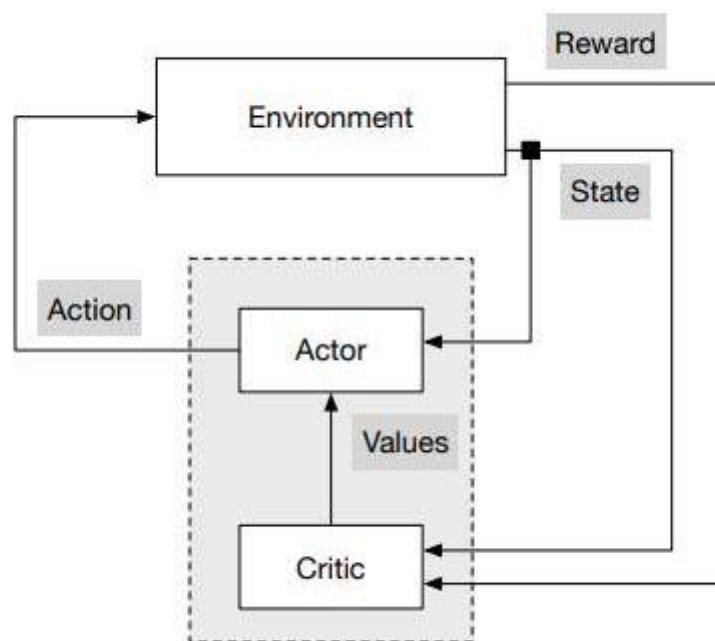


图 2 Actor-Critic 示意图

而 Actor 和 Critic 内部则是两个 network，如图 3。

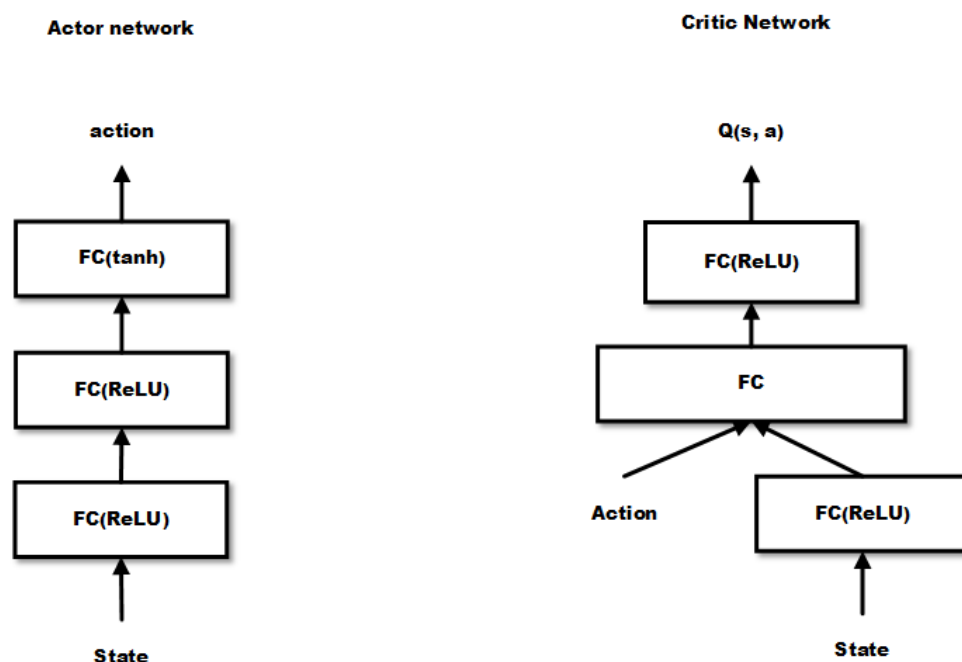


图 3 Actor 和 Critic 网络

而在 A3C 中，多个环境实例上并行异步地执行不同的代理。每个 Agent 将异步更新全局网络。在 A3C 中，存在全局网络和多个 Agent，每个 Agent 具有其自己的一组网络参数。在其他 Agent 与其环境交互的同时，这些 Agent 中的每一个都与其自己的环境副本交互。这比使用单个 Agent 更好的原因是每个 Agent 的经验独立于其他 Agent 的经验。通过这种方式，使得整个训练过程变得更加多样化。

(2) Soft Actor-Critic (SAC)

SAC 同样基于 Actor-Critic，它是一种能在连续的状态和动作空间中有效且稳定的深度强化学习算法。首先其采用了一个 actor-critic 结构，包括分离的策略网络和价值函数网络，其中策略网络是一个随机 actor；同时它采用 off-policy 更新方式，基于历史经验样本进行参数更新；最后它拥有一个熵最大化目标，保证稳定性和探索能力。最大熵强化学习在标准的最大 reward 强化目标上增加了一个最大熵项，提高了探索能力和鲁棒性。相比于其它的 Actor-Critic，其最大的特点在于拥有良好的收敛能力，以及在收敛的过程中具有较高的稳定性。

5. 完善系统。

经过构思设计，本课题中的无人驾驶系统的架构图如图 4。

本项目的整个系统分为六个模块，分别为训练模块、驾驶决策模块、传感信息采集模块、环境感知模块、驱动模块和选项设置。

(1) 训练模块。本模块主要用于训练算法模型，首先通过强化学习 gym 模块建立环境，然后进入神经网络构建模块进行算法模型的搭建，而超参数设置模块则用于调整模型和训练时的超参数。

(2) 驾驶决策模块。本模块是在训练完成后用户进行自动驾驶时使用的模块，用户能够选择自动驾驶或手动驾驶，同时本系统加入了 rss 安全决策模块以保证行驶安全。

(3) 传感信息采集模块。本模块用于获取图片数据和其它需要的传感器信息，并对数据进行预处理。

(4) 环境感知模块。本模块用于感知当前的道路环境，如车道监测、障碍物识别等。

(5) 驱动模块。本模块用于驱动底层的马达与舵机，使上层程序能够更简单地驱动车辆。

(6) 选项设置。本模块用于设置一些可视化设置，如打开/关闭深度视觉图像和语义分割图像的视频，以及用户视角的设置。

6. 训练模型。

通过模拟器提供的 API，让 agent 与之交互，得到视觉数据并使用搭建好的模型进行相应的训练，实验中可以通过调整各超参数来优化训练效果。由于模型的复杂性，训练时可以使用 cuda+cudnn+tensorflow-gpu 驱动 GPU 来让训练模型的过程变得更加高效。模型训练时，应按照流程如图 5。

7. 测试模型。

训练完各个模型后需要对它们进行测试，测试应当保证足够的量，并且尽量保证全面性，让每个模型都测试到尽可能多的情况，如直行道路、弯道、急转弯等。对于各模型在不同情况下的表现需要做下记录，以图表的方式呈现出来，并根据实验结果分析各种模型的在不同情况下的优劣并探究其原因。

8. 迁移学习。

把可用的模型放到无人小车上投入使用，验证模型的实际可用性。观察各模型在实际行驶中的表现是否与测试结果一致，如果出现模型的弱化或无效，则需要分析其原因并以扩充训练集、调整模型、修改超参数等方式来优化模型，使其在实际行驶中有更好的表现。

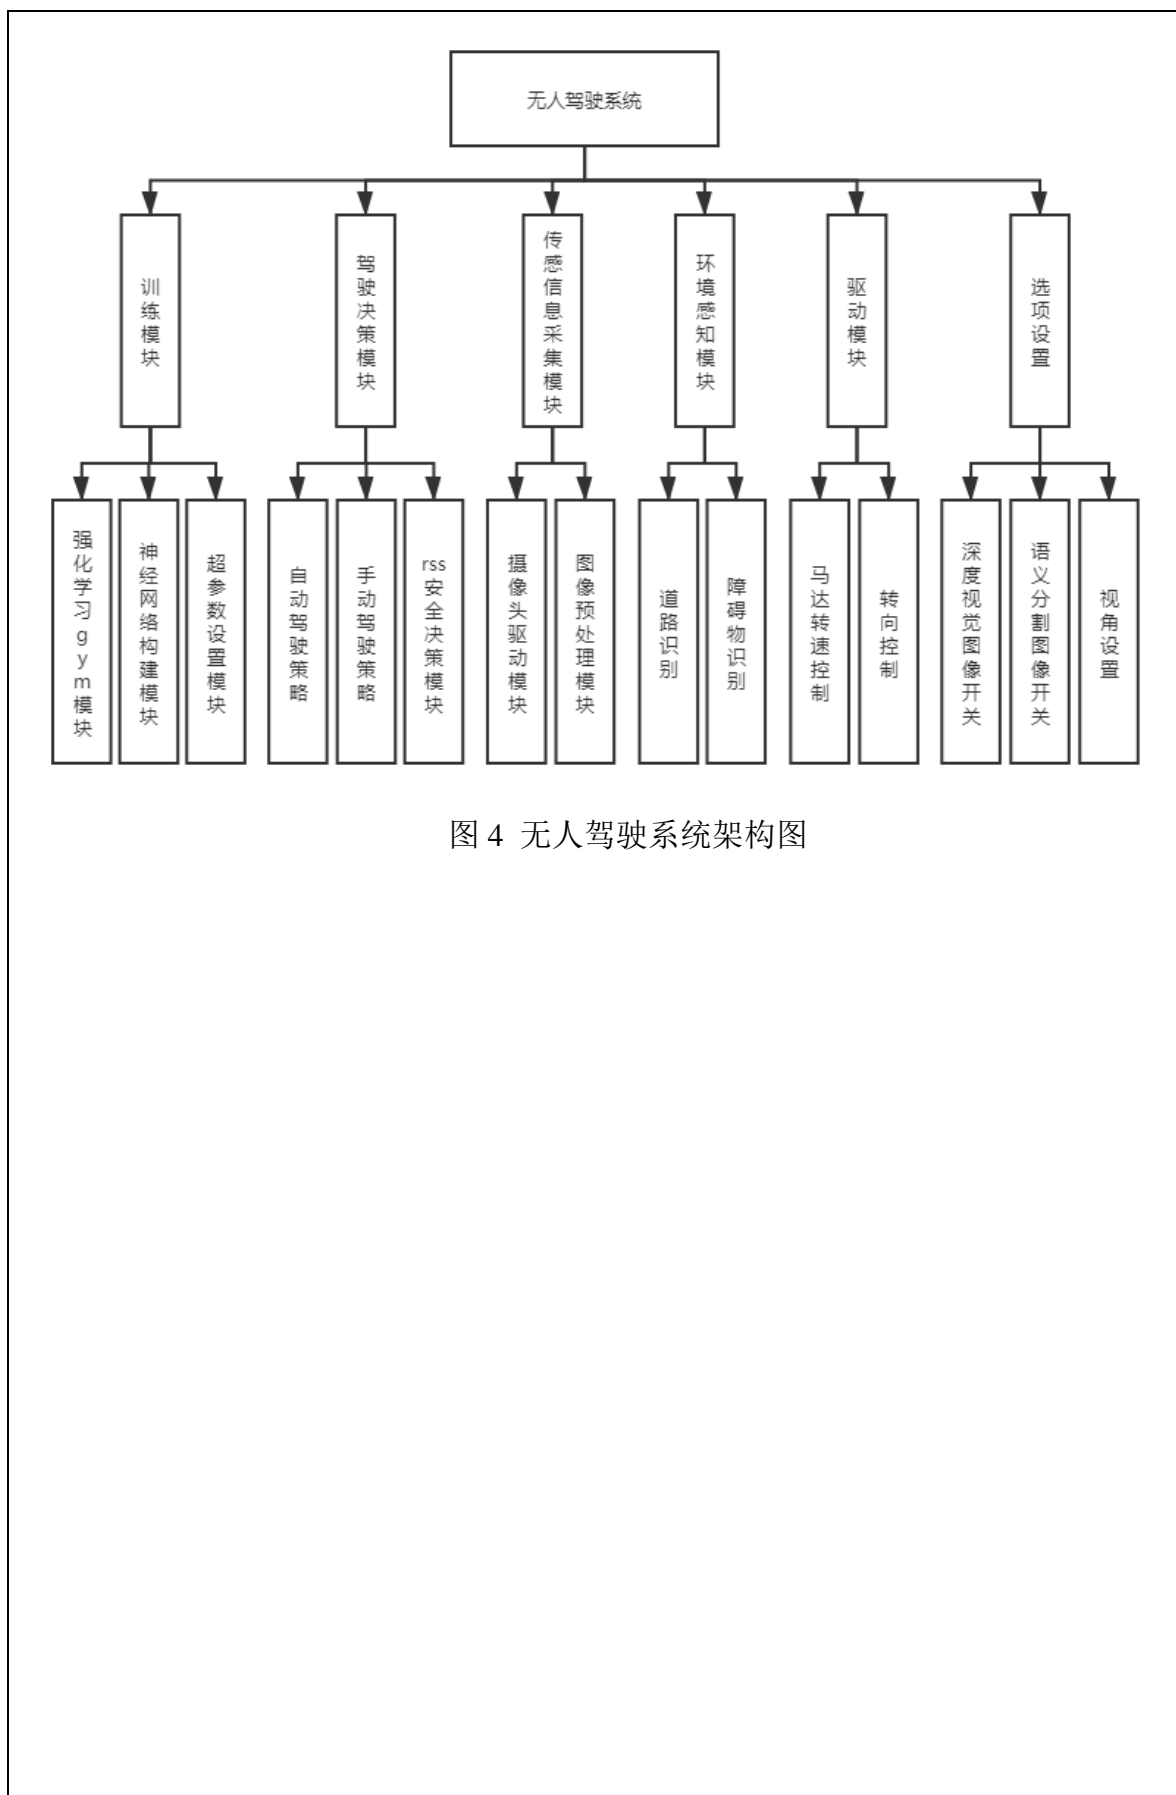


图 4 无人驾驶系统架构图

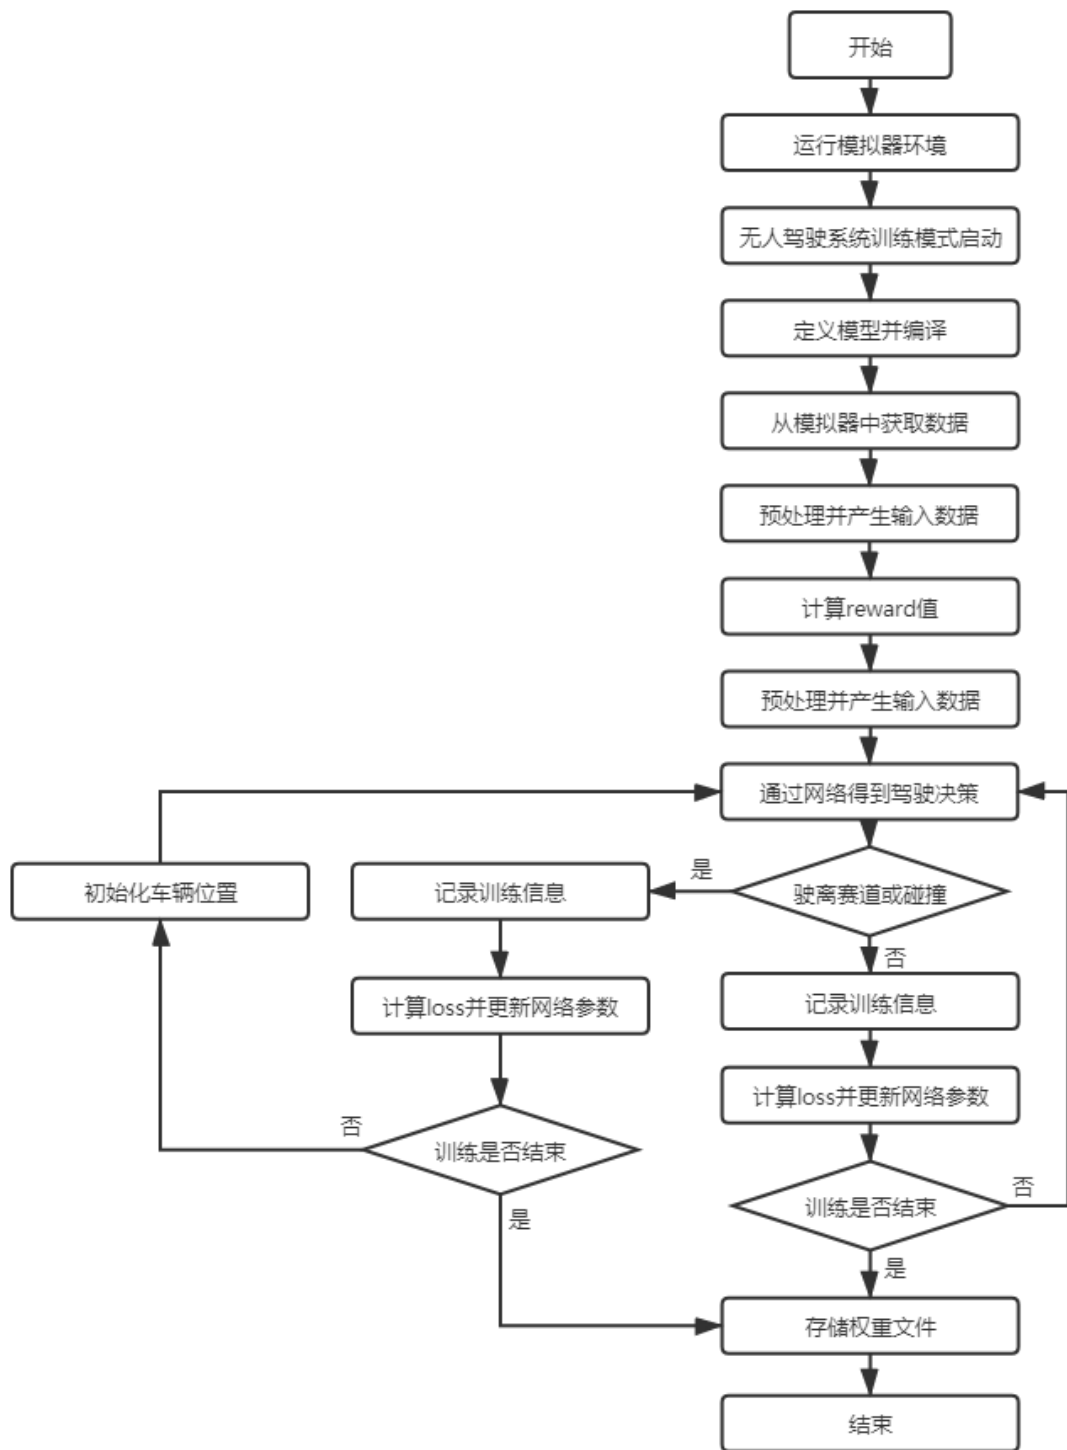


图 5 模型训练流程

当用户使用本系统启动无人驾驶模式时，应按照流程如图 6。



图 6 无人驾驶模式流程图

五、可行性分析

本课题使用到的技术大部分都已经相对成熟，网上能够找到许多研究资料和案例，为笔者的学习提供了良好的途径。实验用的计算机是配备了高配 cpu 和显卡的计算机，能够以非常快的速度进行大量运算，并且已经安装了 Ubuntu 系统、Anaconda 和 Python 等必要的环境，在此之上还成功安装了 CUDA 和 CUDNN, 使其能够使用 gpu 资源对模型进行训练。实验所需的无人小车也已经购买，只需要装配起来就能够投入使用。因此本项目在技术上和经济上都具有很高的可行性。

毕 业 设 计（论文） 开 题 报 告

指导教师意见：

1. 对“文献综述”的评语：

2. 对本课题的深度、广度及工作量的意见和对设计（论文）结果的预测：

3. 是否同意开题：☐同意 ☐不同意

指导教师：_____

201 年 月 日

（时间范围：2019.12.14~12.30，填写完成后删除本行）

所在专业审查意见：

负责人：_____

20 年 月 日

（时间范围：2019.12.30~2020.01.10，填写完成后删除本行）